# DRL Course 2023 Домашнее задание 3

Отчет по выполнению домашнего задания, Nikita Sorokin

### Задание 1

В алгоритме Policy Iteration важным гиперпараметром является gamma. Требуется ответить на вопрос, какой gamma лучше выбирать. Качество обученной политики можно оценивать например запуская среду 1000 раз и взяв после этого средний total\_reward.

Описание алгоритма:

Введем две функции:

$$v_{\pi}(s) := \mathbb{E}_{\pi}[G|S_0 = s], \quad q_{\pi}(s,a) := \mathbb{E}_{\pi}[G|S_0 = s, A_0 = a]$$

Для них можно записать уравнения Беллмана:

$$egin{aligned} v_\pi(s) &= \sum_a \pi(a|s) \Big( R(s,a) + \gamma \sum_{s'} P(s'|s,a) v_\pi(s') \Big) \ q_\pi(s,a) &= R(s,a) + \gamma \sum_{s'} P(s'|s,a) \sum_{a'} \pi(a'|s') q_\pi(s',a') \end{aligned}$$

Из этих соотношений находится связь между функциями  $v_{\pi}(s)$  и  $q_{\pi}(s)$ :

$$egin{aligned} v_\pi(s) &= \sum_a \pi(a|s) q_\pi(s,a) \ q_\pi(s,a) &= R(s,a) + \gamma \sum_{s'} P(s'|s,a) v_\pi(s') \end{aligned}$$

В поставленной задачи награда зависит от следующего состояния поэтому полученная формула для  $v_\pi(s)$  примут вид:

$$q_\pi(s,a) = \sum_{s'} P(s'|s,a) \Big( R(s,a,s') + \gamma v_\pi(s') \Big)$$

#### **Policy Iteration:**

1. (Policy Evaluation)

$$v_\pi^{l+1}(s) = \sum_a \pi(a|s) q_\pi^l(s,a), \quad l \in \overline{0,L-1}$$

Находим  $q_\pi^L(s,a)$  по  $v_\pi^L(s)$ 

```
\pi^{k+1}(a|s) = \left\{ egin{aligned} 1, 	ext{if } a \in argmax_{a' \in A}q_\pi^L(s, a') \ 0, 	ext{else} \end{aligned} 
ight.
```

```
In [1]: import numpy as np
import time
import os
from tqdm import tqdm
from Frozen_Lake import FrozenLakeEnv
import matplotlib.pyplot as plt
import seaborn as sns
from tqdm import tqdm
sns.set()
```

Warning: Gym version v0.24.0 has a number of critical issues with `gym.make` such that the `reset` and `step` functions are called before returning the environment. It is recommend to downgrading to v0.23.1 or upgrading to v0.25.1

```
In [2]: env = FrozenLakeEnv()
```

```
In [14]: class DPAgent():
             def __init__(self, env):
                 self.env = env
                 self.policy = self.init_policy()
             def init_policy(self):
                 policy = {}
                 for state in self.env.get_all_states():
                     policy[state] = {}
                     for action in self.env.get_possible_actions(state):
                          policy[state][action] = 1 / len(self.env.get_possible_actions(state
                 return policy
             def init_v_values(self):
                 v values = {}
                 for state in self.env.get_all_states():
                     v_values[state] = 0
                 return v_values
             def get_q_values(self, v_values, gamma):
                 q values = {}
                 for state in self.env.get_all_states():
                     q_values[state] = {}
                     for action in self.env.get_possible_actions(state):
                          q_values[state][action] = 0
                          for next_state in self.env.get_next_states(state, action):
                              q_values[state][action] += self.env.get_transition_prob(state,
                              q_values[state][action] += gamma * self.env.get_transition_prob
                 return q_values
             def policy_evaluation_step(self, v_values, policy, gamma, algo):
                 q_values = self.get_q_values(v_values, gamma)
                 new v values = self.init v values()
```

```
for state in self.env.get_all_states():
        new_v_values[state] = 0
        if algo == 'policy':
            for action in self.env.get_possible_actions(state):
                new_v_values[state] += policy[state][action] * q_values[state][
        if algo == 'value':
            try:
                new_v_values[state] = max(q_values[state].values())
            except Exception:
                new_v_values[state] = 0
    return new_v_values
def policy_evaluation(self, policy, gamma, eps, v_values, algo):
    new v values = self.policy evaluation step(v values, policy, gamma, algo)
    delta_v = abs(np.array(list(v_values.values())) - np.array(list(new_v_value
    while(max(delta_v) > eps):
        v_values = new_v_values
        new_v_values = self.policy_evaluation_step(v_values, policy, gamma, alg
        delta_v = abs(np.array(list(v_values.values())) - np.array(list(new_v_v
    q_values = self.get_q_values(v_values, gamma)
    return q_values, v_values
def policy_improvement(self, q_values):
    policy = \{\}
    for state in self.env.get_all_states():
        policy[state] = {}
        argmax_action = None
        max_q_value = float('-inf')
        for action in self.env.get_possible_actions(state):
            policy[state][action] = 0
            if q_values[state][action] > max_q_value:
                argmax_action = action
                max_q_value = q_values[state][action]
        policy[state][argmax_action] = 1
    return policy
def train(self, iter_n, eps, gamma, algo, save_v_values=False):
    policy = self.init_policy()
    v_values = self.init_v_values()
    for _ in range(iter_n):
        if save_v_values == False:
            v_values = self.init_v_values()
        q_values, v_values = self.policy_evaluation(policy, gamma, eps, v_value
        policy = self.policy_improvement(q_values)
    self.policy = policy
    return policy
def validation(self, validation_n):
    total rewards = []
```

```
for _ in range(validation_n):
        total_reward = 0
        state = self.env.reset()
        while(True):
            action = np.random.choice(self.env.get_possible_actions(state), p=1
            state, reward, done, _ = self.env.step(action)
            total reward += reward
            if done:
                break
        total_rewards.append(total_reward)
    return np.mean(total_rewards)
def visualize_trajectory(self, policy):
    total reward = 0
    state = self.env.reset()
    done = False
    while(done == False):
        action = np.random.choice(self.env.get_possible_actions(state), p=list(
        state, reward, done, _ = self.env.step(action)
        total_reward += reward
        clear_output(wait=True)
        self.env.render()
        time.sleep(1)
        if done:
            break
```

Посмотрим сколько итераций mean total reward от количества итераций алгоритма при фиксированных  $\gamma$  и  $\varepsilon$ :

```
In [42]:

def iter_n_search(max_iter, eps, gamma, algo, validation_n, save_v_values=False):
    fig, axs = plt.subplots(figsize=(10, 6))

mean_rewards = []
    for iter in range(0, max_iter + 1):
        agent = DPAgent(env)
        agent.train(iter, eps, gamma, algo, save_v_values)
        mean_total_reward = agent.validation(validation_n)
        mean_rewards.append(mean_total_reward)

iters = np.arange(0, max_iter + 1)

axs.set_xlabel('algorithm iteration')
    axs.set_ylabel('mean total reward')
    axs.plot(iters, mean_rewards, label=f'eps={eps}, gamma={gamma}')
    plt.legend()
    plt.savefig('iter_n_search.png')

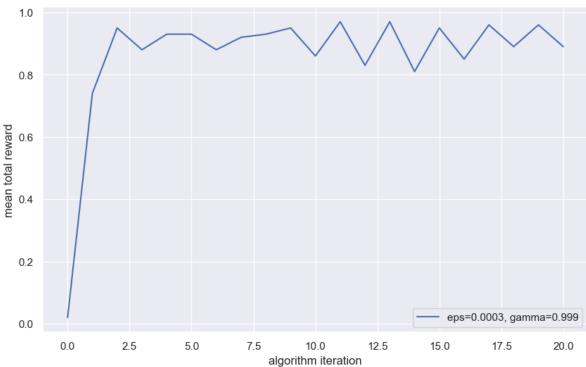
return mean_rewards
```

```
In [123... max_iter = 20 eps = 0.0003
```

```
gamma = 0.999
algo = 'policy'
validation_n = 100

mean_rewards = iter_n_search(max_iter, eps, gamma, algo, validation_n)
print(mean_rewards)
```

[0.02, 0.74, 0.95, 0.88, 0.93, 0.93, 0.88, 0.92, 0.93, 0.95, 0.86, 0.97, 0.83, 0.97, 0.81, 0.95, 0.85, 0.96, 0.89, 0.96, 0.89]



Можно сделать вывод, что с примерно с третьей итерации алгоритм выходит на плато. Будем использовать  $iter_n = 5$ 

С помощью grid-search будем искать наилучшие параметры  $\gamma$  и  $\varepsilon$ :

```
In [94]: def grid_search(iter_n, params, algo, validation_n):
    results = np.zeros((params['gamma'].size, params['eps'].size))

for i, gamma in tqdm(enumerate(params['gamma'])):
    for j, eps in enumerate(params['eps']):
        agent = DPAgent(env)
        policy = agent.train(iter_n, eps, gamma, algo)
        mean_total_reward = agent.validation(validation_n)
        results[i][j] = mean_total_reward

return results
```

```
In [102...
params = {
    'gamma': np.array([0.9, 0.99, 0.9999, 1]),
    'eps': np.array([0.03, 0.00003])
}
```

```
In [103... | iter_n = 5
         algo = 'policy'
         validation n = 1000
         results = grid_search(iter_n, params, algo, validation_n)
        4it [01:44, 26.10s/it]
In [110... for i, gamma in enumerate(params['gamma']):
            for j, eps in enumerate(params['eps']):
                print(f'gamma = {gamma},\t eps = {eps}: \t mean_total_reward = {results[i,
                         eps = 0.03:
                                        mean total reward = 0.741
         gamma = 0.9,
         gamma = 0.9,
                       eps = 0.0003:
                                        mean_total_reward = 0.714
         gamma = 0.9, eps = 3e-06:
gamma = 0.99, eps = 0.03:
                                        mean_total_reward = 0.746
                                        mean_total_reward = 0.774
         gamma = 0.99,
                        eps = 3e-06:
                                        mean_total_reward = 0.852
         gamma = 0.9999, eps = 0.03:
gamma = 0.9999, eps = 0.0003:
                                        mean total reward = 0.754
                                        mean_total_reward = 0.996
         gamma = 0.9999, eps = 3e-06:
                                        mean_total_reward = 0.999
                       eps = 0.03:
                                      mean_total_reward = 0.756
         gamma = 1.0,
         gamma = 1.0,
                       eps = 0.0003:
                                        mean_total_reward = 0.997
         gamma = 1.0,
                       eps = 3e-06:
                                        mean_total_reward = 0.994
```

### Задание 2

На шаге Policy Evaluation мы каждый раз начинаем с нулевых values. А что будет если вместо этого начинать с values обученных на предыдущем шаге? Будет ли алгоритм работать? Если да, то будет ли он работать лучше?

В функцию train добавим условие при выполнении которого v\_values будут не обнуляться, а передаваться в следующую итерациюк policy\_evaluation.

Следовательно, лучшие параметрами являются:  $\gamma = 0.9999$  и  $\varepsilon = 0.00006$ 

Реализация:

• • •

```
In [19]: def grid_search(iter_n, params, algo, validation_n):
             results = np.zeros((params['gamma'].size, params['eps'].size, 2))
             for i, gamma in tqdm(enumerate(params['gamma'])):
                 for j, eps in enumerate(params['eps']):
                     agent1 = DPAgent(env)
                     agent2 = DPAgent(env)
                     agent1.train(iter_n, eps, gamma, algo, save_v_values=False)
                     agent2.train(iter_n, eps, gamma, algo, save_v_values=True)
                     mean_total_reward1 = agent1.validation(validation_n)
                     mean_total_reward2 = agent2.validation(validation_n)
                     results[i][j][0] = mean_total_reward1
                     results[i][j][1] = mean_total_reward2
             return results
In [39]: params = {
             'gamma': np.array([0.99, 0.9999]),
             'eps': np.array([0.003, 0.000003])
         }
In [40]: iter_n = 10
         algo = 'policy'
         validation_n = 1000
         results = grid_search(iter_n, params, algo, validation_n)
         2it [00:57, 28.90s/it]
In [41]: for i, gamma in enumerate(params['gamma']):
             for j, eps in enumerate(params['eps']):
                 print(f'gamma = {gamma},\t eps = {eps}, \t save_v_values = False:\t mean_to
                 print(f'gamma = {gamma},\t eps = {eps}, \t save_v_values = True: \t mean_to
         gamma = 0.99,
                         eps = 0.003,
                                         save v values = False: mean total reward = 0.768
         gamma = 0.99,
                        eps = 0.003,
                                        save_v_values = True: mean_total_reward = 0.873
                       eps = 3e-06,
         gamma = 0.99,
                                         save_v_values = False: mean_total_reward = 0.852
         gamma = 0.99,
                        eps = 3e-06, save_v_values = True:
                                                                 mean_total_reward = 0.865
         gamma = 0.9999, eps = 0.003, save_v_values = False: mean_total_reward = 0.974
                                         save_v_values = True:
         gamma = 0.9999, eps = 0.003,
                                                                 mean_total_reward = 0.968
         gamma = 0.9999, eps = 3e-06, save_v_values = False: mean_total_reward = 1.0
         gamma = 0.9999, eps = 3e-06, save v values = True: mean total reward = 0.998
```

агента, который запоминает  $v_values$ . Однако в целом, в заданной среде различия не так существенны и даже подобрать такие значения довольно проблематично.

## Задание 3

Написать Value Iteriation. Исследовать гиперпараметры (в том числе gamma). Сравнить с Policy Iteration. Поскольку в Policy Iteration есть еще внутренний цикл, то адекватным сравнением алгоритмов будет не графики их результативности относительно внешнего цикла, а графики относительно, например, количества обращения к среде.

Определим 2 новые функции:

$$v_*(s) = \max_{\pi} v_\pi(s), \quad q_*(s,a) = \max_{\pi} v_\pi(s,a)$$

Связь между ними выводится из соответствующих уравнений Беллмана:

$$v_*(s) = \max_{a \in A} q_*(s,a), \quad q_*(s,a) = R(s,a) + \gamma \sum_{s'} P(s'|s,a) v_*(s')$$

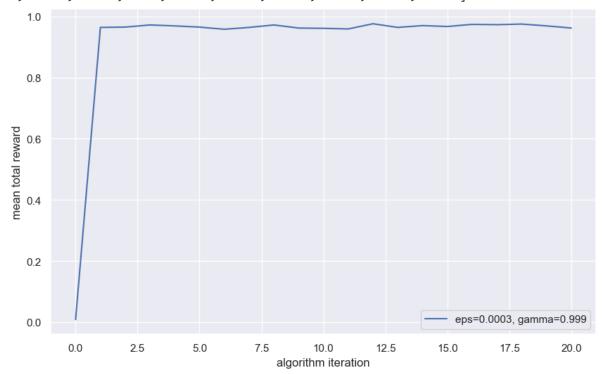
В алгоритме Value Iteration вычисляются функции  $v_*(s),\ q_*(s,a)$  в то время как в алгоритме Policy Iteration вычисляются  $v_\pi(s),\ q_\pi(s,a)$ . Так как формулы вычисления q(s,a) по v(s) совпадают в написанной реализации Policy Iteration надо только изменить формулу вычисления v(s) по q(s,a).

Реализация:

```
In [43]: max_iter = 20
    eps = 0.0003
    gamma = 0.999
    algo = 'value'
    validation_n = 1000

mean_rewards = iter_n_search(max_iter, eps, gamma, algo, validation_n)
    print(mean_rewards)
```

[0.009, 0.964, 0.965, 0.972, 0.969, 0.965, 0.958, 0.964, 0.972, 0.962, 0.961, 0.95 9, 0.976, 0.964, 0.97, 0.967, 0.974, 0.973, 0.975, 0.969, 0.962]



Алгоритм сходится к оптимальной политики со второго шага. В дальнейшем будем рассматривать iter\_n = 5.

```
In [49]: def grid_search(iter_n, params, validation_n):
             results = np.zeros((params['gamma'].size, params['eps'].size, 2))
             for i, gamma in tqdm(enumerate(params['gamma'])):
                 for j, eps in enumerate(params['eps']):
                     agent1 = DPAgent(env)
                     agent2 = DPAgent(env)
                     agent1.train(iter_n, eps, gamma, algo='policy')
                     agent2.train(iter_n, eps, gamma, algo='value')
                     mean_total_reward1 = agent1.validation(validation_n)
                     mean_total_reward2 = agent2.validation(validation_n)
                     results[i][j][0] = mean_total_reward1
                     results[i][j][1] = mean_total_reward2
             return results
In [50]: params = {
             'gamma': np.array([0.99, 0.9999]),
             'eps': np.array([0.003, 0.000003])
In [51]: iter_n = 5
         validation_n = 1000
         results = grid_search(iter_n, params, validation_n)
```

```
0it [00:00, ?it/s]2it [01:01, 30.74s/it]
```

```
In [53]: for i, gamma in enumerate(params['gamma']):
             for j, eps in enumerate(params['eps']):
                 print(f'gamma = {gamma},\t eps = {eps}, \t algo = \'policy\': mean_total_re
                 print(f'gamma = {gamma},\t eps = {eps}, \t algo = \'value\' : mean_total_re
         gamma = 0.99,
                          eps = 0.003,
                                          algo = 'policy': mean_total_reward = 0.748
         gamma = 0.99,
                                          algo = 'value' : mean_total_reward = 0.831
                          eps = 0.003,
                                          algo = 'policy': mean_total_reward = 0.852
         gamma = 0.99,
                        eps = 3e-06,
         gamma = 0.99,
                         eps = 3e-06,
                                          algo = 'value' : mean_total_reward = 0.844
                                          algo = 'policy': mean_total_reward = 0.959
         gamma = 0.9999, eps = 0.003,
                                          algo = 'value' : mean_total_reward = 0.862
         gamma = 0.9999, eps = 0.003,
                                          algo = 'policy': mean_total_reward = 1.0
         gamma = 0.9999, eps = 3e-06,
         gamma = 0.9999, eps = 3e-06,
                                          algo = 'value' : mean_total_reward = 0.998
```